

BLOCO 1

A Base e a Semântica

Por que LLMs não bastam sozinhos — e como o RAG resolve isso



Cobre: Fundamentos de RAG + Embeddings e Similaridade Vetorial



O problema começa aqui

Usuário


"Qual o prazo para recurso administrativo segundo a Resolução nº 12/2025 da nossa instituição?"

LM Puro

"De acordo com a legislação vigente, o prazo padrão para recurso administrativo é de **15 dias úteis** a partir da publicação do ato, conforme estabelecido nos princípios gerais do direito administrativo brasileiro."

⚠ O modelo respondeu com confiança. A Resolução nº 12/2025 não existe na base de treinamento. O prazo foi inventado.

Em ambientes institucionais, uma resposta plausível-mas-errada é mais perigosa que uma resposta incerta.




Alucinação: não é mentira, é probabilidade sem âncora

O que o LLM NÃO tem:

- > ✗ Acesso à Resolução nº 12/2025
- > ✗ Guardrails nas respostas
- > ✗ Noção de "certo" vs "plausível"
- > ✗ Mecanismo de incerteza automático

O LLM não "mente" — ele completa o texto estatisticamente. A alucinação é uma propriedade estrutural, não um bug corrigível com mais GPU.



O LLM puro: o que ele realmente não consegue fazer

CAPACIDADE	LLM Puro	Com RAG
Acessar documentos internos da sua instituição	✗	✓
Conhecer normas publicadas após o treinamento	✗	✓
Citar a fonte exata de uma afirmação	✗	✓
Saber quando não sabe a resposta	⚠ Raramente	✓ Com instrução
Ter rastreabilidade para auditoria	✗	✓
Ser atualizado sem re-treinamento	✗	✓

Um LLM genérico nunca conhecerá a Resolução que sua instituição publicou ontem.

Por que não simplesmente fazer Fine-Tuning?



Analogia: Fine-tuning é contratar um funcionário e treiná-lo por 6 meses. RAG é dar ao funcionário um manual atualizado e dizer: "leia antes de responder."

Critério	Prompt-Only	Fine-Tuning	RAG
Custo de implantação	✓ Baixo	✗ Alto	✓ Médio
Velocidade de atualização	✗ Manual	✗ Re-treinar	✓ Atualizar docs
Rastreabilidade de fonte	✗ Nenhuma	✗ Nenhuma	✓ Cita documentos
Escala com novos dados	✗ Não escala	✗ Lento	✓ Add ao índice
Risco de alucinação	✗ Alto	⚠ Médio	✓ Reduzido


RAG evita re-treinamento. Quando a norma muda, você atualiza o documento — não o modelo.

Arquitetura RAG: dois planos, um pipeline

Information Retrieval + Linguagem Natural +
Geração = RAG

- > **Plano Superior (Fase Offline):** Roda uma vez (ou periodicamente) para preparar e indexar a base de conhecimento.
- > **Separação Clara:** Design isola o processamento pesado da consulta em tempo real.
- > **Plano Inferior (Fase Online):** Roda a cada requisição do usuário.

RAG não é uma biblioteca, é um **padrão arquitetural**




Fase Offline — Como o conhecimento entra no sistema

Equivalente ao seu pipeline de ETL batch

- **Fonte & Extração:** PDFs, normas lidos e texto extraído.
- **Limpeza:** Remoção de ruídos, cabeçalhos e quebras de linha irregulares.
- **Chunking:** Divisão em segmentos menores com sobreposição (overlap) opcional para não cortar contexto.
- **Embeddings:** Transformação do texto em vetores numéricos semânticos.
- **Indexação:** Armazenamento no Banco de Dados Vetorial.

Esta fase roda **uma vez**. É separada da consulta por design — não pela conveniência.

`src/1_ingestion.py` · `src/2_indexing.py`




Fase Online — O caminho da pergunta até a resposta

Equivalente ao seu request-response de API

- > **Pergunta & Embedding:** Transforma a dúvida do usuário em vetor numérico.
- > **Busca Top-K:** Encontra os blocos de texto (chunks) mais matematicamente similares no banco vetorial.
- > **Contexto:** Monta os blocos selecionados junto com a pergunta em um prompt instrucional.
- > **LLM & Resposta:** O modelo lê exclusivamente o contexto fornecido e gera a síntese final.

O LLM nunca faz a busca. Ele recebe um "pacote de evidências" já preparado.



Os 6 componentes de todo sistema RAG



1 — Fonte de Dados

PDFs, TXTs, normas, atas, contratos, bases internas institucionais.



2 — Ingestão & Limpeza

Extração por página, normalização, remoção de ruído textual.



3 — Embeddings

Representação vetorial abstrata do significado semântico do texto.



4 — Banco Vetorial

ChromaDB, FAISS, pgvector — armazena vetores e seus metadados.



5 — Retriever

Mecanismo de busca top-K por similaridade semântica.



6 — LLM

Gera a resposta final e articulada com base no contexto recuperado.

Memorize esses 6. Qualquer falha em um deles degrada todo o sistema.

Onde RAG resolve problemas reais



Normas & Regimentos

"Qual o prazo para revisão de nota conforme o Regimento de 2025?"



Apoio Jurídico & Compliance

"Este contrato viola a cláusula da Resolução 045/2024?"



Atas & Decisões

"O que foi deliberado na reunião do Conselho de março?"



Gestão Acadêmica

"Quais os critérios de aprovação no Regulamento de Graduação?"



Suporte Técnico Interno

"Como configurar VPN segundo o manual TI versão 3.1?"



Transparência & Auditoria

"Onde está a portaria que autorizou esse processo licitatório?"

Em todos esses casos: dados privados, sensíveis ao contexto, que nenhum LLM genérico conhece.


Embedding: transformando significado em coordenadas

"Pense como um hash semântico. Em vez de mapear uma string para um número inteiro fixo, o embedding mapeia o *significado* para um ponto em um espaço de 384 dimensões."

- **Entrada:** Texto natural (ex: "prazo para trancamento").
- **Processamento:** Passa por um modelo neural (ex: nomic-embed-text).
- **Saída:** Um array numérico de alta dimensionalidade.

Dois textos diferentes mas com o mesmo significado geram vetores *próximos* neste espaço.

```
src/config.py → EMBEDDING_MODEL = "nomic-embed-text"
```




No espaço vetorial, significado vira distância

(Projeção 2D simplificada — na prática são 384 dimensões)

- > **Cluster Azul (Pessoas):** "professor", "docente", "mestre", "educador". Estão próximos.
- > **Cluster Verde (Documentos):** "norma", "resolução", "regulamento".
- > **Relações Ocultas:** Cluster Azul e Verde não são sinônimos, mas a busca entende a relação semântica do domínio acadêmico/institucional.
- > **Isolamento:** O termo "receita de bolo" cai em um ponto distante de todos no espaço vetorial.

A busca vetorial encontra os "vizinhos mais próximos" da sua pergunta. Não procura palavras — procura *significado*.




Similaridade do Cosseno: medir ângulo, não distância

"Não importa o *tamanho* dos documentos — importa o *ângulo* entre eles. Dois textos de tamanhos diferentes sobre o mesmo assunto formam um ângulo próximo de zero. $\text{Cos}(0^\circ) = 1.0$ "

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$$

Ângulo θ	$\cos(\theta)$	Interpretação
0°	1.0	Idênticos
45°	0.7	Relacionados
90°	0.0	Sem relação

Em RAG, ordenamos os chunks por $\cos(\theta)$ DESC LIMIT k.



No código: como embeddings são gerados localmente

src/config.py

```
# 0 "painel de controle" do sistema
EMBEDDING_MODEL = "nomic-embed-text" # contrato imutável entre ingestão e retrieval
OLLAMA_BASE_URL = "http://localhost:11434" # 100% local, zero dados na nuvem
VECTOR_DB_PATH = "./chroma_db"
CHUNK_SIZE = 1200 # em caracteres (~300 tokens)
CHUNK_OVERLAP = 200 # ~17% de overlap
TOP_K = 5 # chunks enviados ao LLM
```

src/1_ingestion.py

```
# Como o embedding é gerado por chunk
def embed_text(text: str) -> list[float]:
    response = requests.post(
        f"{OLLAMA_BASE_URL}/api/embeddings",
        json={"model": EMBEDDING_MODEL, "prompt": text}
    )
    return response.json()["embedding"]
# retorna lista de 768 floats - o vetor semântico do chunk
```

- EMBEDDING_MODEL: Se mudar aqui, reindexar **tudo**.
- localhost:11434: Ollama local — nenhum dado sai desta máquina.
- CHUNK_SIZE: Em produção, meça em tokens. 1200 chars ≈ 300 tokens.

Escolha do modelo de embedding: trade-offs reais

⚠ Um bom LLM não corrige embeddings ruins. A qualidade do RAG está na fase de embedding + retrieval.


Modelo	Dimensões	Velocidade	Qualidade PT-BR	Uso Recomendado
all-MiniLM-L6-v2	384	⚡ Muito rápido	⚠ Médio	Prototipagem rápida
nomic-embed-text (Ollama)	768	✅ Rápido	✅ Bom	Stack deste curso
multilingual-e5-large	1024	🐢 Médio	✅✅ Excelente	Produção / Multi-idioma

Image Sources



<https://media.crayon.com/2025-10-07/Ptl3eeOdSgaxW05Ri87eKA.webp>

Source: www.crayon.com



<https://cdn.dribbble.com/userupload/43417415/file/original-3a4c6454500a9fdfa0fc839bc321c12c.jpg?resize=752x&vertical=center>

Source: dribbble.com



<https://amirteymoori.com/wp-content/uploads/2025/01/llm-transformer-architecture-self-attention-training-rlhf-diagram-1024x640.webp>

Source: amirteymoori.com



https://miro.medium.com/0*69gjBJ1-pl1PDqcY

Source: ai.gopubby.com



<https://media2.dev.to/dynamic/image/width=1280,height=720,fit=cover,gravity=auto,format=auto/https%3A%2F%2Fdev-to-uploads.s3.amazonaws.com%2Fuploads%2Farticles%2Fon4d9uap8cgwxqkjxerf.png>

Source: dev.to

Image Sources



https://developers.google.com/static/machine-learning/crash-course/embeddings/images/one_hot_hot_dog_embedding.png

Source: developers.google.com



<https://storage.googleapis.com/lids-media/images/cosine-similarity-vectors.original.jpg>

Source: www.learndatasci.com
